# Faster rcnn caffe 代码详解

符号说明: GT: ground truth

- 1.模型的流程:
  - 单张图片进来先 resize
  - resize 过后的图片进入基础网络得到最后一层的特征层: conv5([1,h,w,256])
  - conv5 进入 RPN,通过 1\*1 的卷积得到 anchors 的分类和回归的预测分类的输出 shape: [1,h,w,2\*9],2 表示前景和背景,9 表示 anchor数目

回归的输出 shape: [1,h,w,4\*9],4 为坐标,9 为 anchor 数目

- 在 rpn.anchor\_target\_layer 层中,制作 RPN 层的标签。 (训练时才有)
  - 1. 生成 anchors([K,A,4],K=w\*h,A=9) → reshape 到[K\*A,4] → 去除在图片之外的 anchors ,这时剩余的 anchor 为[N,4]
  - 2. 为 anchor 打分类标签(shape 为[N,1]), 规则为:
    - a.与 GT 的 IOU 最大的几个 anchor 标为 1(前景)。
    - b.与 GT 的 IOU 最大值在 0.7~1 之间的标为 1。
    - c.与 GT 的 IOU 最大值在 0~0.3 的标记为 0(背景)。
    - d.没有被标记的 anchor 标记为-1(不关心)。
    - e.如果前景数目超过 128,则将多余的 anchor 标记为-1
    - f.如果背景数目超过256-num(前景),则将多余的标为-1
  - 3. 为 anchor 打回归标签(shape 为[N,4]): 计算在图像内的 anchor([N,4])到与之 IOU 最大的 GT 的偏差。
  - 4. 计算 inside\_weight(shape 为[N,4]):
    只有前景的 anchor 才会计算 anchor 回归的 loss,所以这个 weight 就是为了标记前景样本。
  - 5. 计算 outside\_weight(shape 为[N,4]): outside\_weight 是前景和背景的一个加权。
  - 6. 将打好的标签和 weight 映射到 $[K*A,\sim]$ 空间。
  - 7. 把[K\*A,~]reshape 到对应的输出 shape。
- 计算 RPN 层的 loss
- 生成 proposal
  - 1. 将之前的 rpn\_bbox\_pred(shape 为[1,h,w,4\*9]) reshape 到 [h\*w\*9,4] → 用其调整 anchors 得到的结果称为 proposal (shape 为[h\*w\*9,4])

- 2. 将 proposal 裁剪到图像大小之内
- 3. 根据之前的 rpn\_cls\_score(shape 为[1,h,w,2\*9]),取前景得分 score (shape 为[1,h,w,9])  $\rightarrow$  reshape 到[h\*w\*9,1]。
- 4. 去除尺寸(长,宽)小于阈值的 proposals,剩下的 shape 为[N1,4], 和其前景得分的 shape[N1,1]。
- 5. 根据 proposal 的前景得分排序,选取出前 6000 个 proposal,这时的 proposal.shape=[6000,4],score.shape=[6000,1]
- 6. 对剩下的 6000 个框进行 NMS
- 7. 剩下的框,根据得分选取前 2000 个框作为 RPN 层的输出。输出 2000 个框的位置信息,即输出的 shape 为[2000,4]
- rpn.proposal\_target\_layer 层。根据 RPN 层的产生的 2000 个候选框选出 128 个 ROI。制作其分类和回归的标签,还有两个回归的权重 (inside\_weight,outside\_weight)
  - 1. 计算 proposals 与 GT 的 IOU,IOU 大于 0.5 的为前景,小于 0.5 大于 0.1 的为背景。前景不超过 32 个,背景不超过 128-#前景。
  - 2. 根据选出的前景背景的 index,为其打上分类标签,背景打为 0,前景为与其最大 IOU 的 GT 的标签。labels.shape = [128,1]
  - 3. 根据选出的前景背景的 index,索引出其坐标,再与其最接近的 GT 算出 bbox\_target, bbox\_target.shape=[128,4]。
  - 4. 将 bbox\_target 做成网络预测的 shape,并生成 inside\_weight。输入为 labels 和 bbox\_target。输出的 shape[128,4\*num\_class],inside\_weight 的 shape 也为[128,4\*num\_class],是前景的一个mask。
  - 5. outside\_weight 与 inside\_weight 相同。
- ROIPooling: 用上一层产生的 rois,和基础网络出来的 conv5 特征,计算 rois 的特征。即使 roi 的大小会不一样,但是经过这层之后的特征都是一样的了
- 两个全连接层
- 全连接之后,接一个全连接产生分类预测,接另外一个全连接层产生回归预测。
- 用之前做的 roi\_bbox\_target 和 roi\_labels,inside\_weight, outside\_weight,产生分类和回归的 loss

# 2.模型细节

给出 anchor 的分类(前景和背景)和位置预测的标签,还有两个权重,这一层主要是为计算 RPN 的 loss 做标签

```
layer {
  name: 'rpn-data'
  type: 'Python'
 bottom: 'rpn cls score'
 bottom: 'gt boxes'
 bottom: 'im info'
 bottom:
          'data'
  top: 'rpn_labels'
 top: 'rpn bbox targets'
  top: 'rpn bbox inside weights'
  top: 'rpn bbox outside weights'
 python_param {
    module: 'rpn.anchor target layer'
    layer: 'AnchorTargetLayer'
    param_str: "'feat_stride': 16"
```

## 1.生成 anchor:

a.生成左上角的9个anchor(3个scale,3个ratio)

```
anchor = np.array([[ -83., -39., 100., 56.], [-175., -87., 192., 104.], [-359., -183., 376., 200.], [-55., -55., 72., 72.], [-119., -119., 136., 136.], [-247., -247., 264., 264.], [-35., -79., 52., 96.], [-79., -167., 96., 184.], [-167., -343., 184., 360.]])
```

三个连在一起的框的 ratio 是相同的,每隔两个框的 scale 是相同的。

anchor 的大小和 ratio 由下列三个参数控制:

# b.生成偏移量:

偏移量是基于特征图的大小和 resize 过后的图到特征图的缩放倍数来等距离生成的。

\_feat\_stride 为图片经过基础网络之后生成特征图的缩放倍数,

width 和 height 是特征图的宽和高。 所以 anchor 是原图 resize 之后的图中的固定框。

c.由 9 个 anchor 和生成的偏移量来生成全图的 anchor:

其中 K = feature\_h\*feature\_w,A=9

2.对 anchor 的一些简单处理:

只保留在图片之内的一些框:

```
# only keep anchors inside the image
inds_inside = np.where(
   (all_anchors[:, 0] >= -self._allowed_border) &
   (all_anchors[:, 1] >= -self._allowed_border) &
   (all_anchors[:, 0] < im_info[0] + self._allowed_border) & # width
   (all_anchors[:, 0] < im_info[0] + self._allowed_border) # height
)[0]</pre>
```

其中 im\_info 为图片 resize 之后的大小,这个保存在 LMBD 之中。 之后打标签的 anchor 都在这里面选

#### 3.分类标签:

对上一步产生的 anchor 分配 target label, 前景 or 背景, 以便训练 rpn

- 1. 对于每个 gt box,找到与他 iou 最大的 anchor 然后设为正样本
- 2. 对于每个 anchor 只要它与任意一个 gt box iou>0.7 即设为正样本
- 3. 对于每个 anchor 它与任意一个 gt box iou 都<0.3 即设为负样本
- 4. 不是正也不是负的 anchor 被忽略

## a.初始化标签:

```
# label: 1 is positive, 0 is negative, -1 is dont care
labels = np.empty((len(inds_inside), ), dtype=np.float32)
labels.fill(-1)
```

1为正样本,0为负样本,-1为不关心的样本

b.计算候选的 anchor 与真实框 IOU,并计算所有 anchor 与真实框的最大值及其位置,所有真实框与 anchor 的最大值及其位置。

#### c.根据上面算得的两个指标来为 anchor 打分类标签:

```
if not cfg.TRAIN.RPN_CLOBBER_POSITIVES:
    # assign bg labels first so that positive labels can clobber them
    labels[max_overlaps < cfg.TRAIN.RPN_NEGATIVE_OVERLAP] = 0

# fg label: for each gt, anchor with highest overlap
labels[gt_argmax_overlaps] = 1

# fg label: above threshold IOU
labels[max_overlaps >= cfg.TRAIN.RPN_POSITIVE_OVERLAP] = 1

if cfg.TRAIN.RPN_CLOBBER_POSITIVES:
    # assign bg labels last so that negative labels can clobber positives
labels[max_overlaps < cfg.TRAIN.RPN_NEGATIVE_OVERLAP] = 0</pre>
```

所有 anchor 与真实框的最大值及其位置(gt\_max\_overlaps,gt\_argmax\_overlaps): 表示几个与真实框最接近的 anchor。这里得到的几个 anchor 标为正样本

所有真实框与 anchor 的最大值及其位置(max\_overlaps,argmax\_overlaps): 表示 anchor 与最接近的 GT 是所少。这里最大值大于阈值(0.7)的 anchor 标为正样本,小于阈值(0.3)的标为负样本,位于 之间的标为不关心样本。

d.正负样本之和为 256。

如果正样本超过 128,则将多余的正样本标记为不关心样本。 其中  $num_fg = int(0.5*256)$ 

```
# subsample positive labels if we have too many
num_fg = int(cfg.TRAIN.RPN_FG_FRACTION * cfg.TRAIN.RPN_BATCHSIZE)
fg_inds = np.where(labels == 1)[0]
if len(fg_inds) - num_fg:
    disable_inds = npr.choice(
        fg_inds, size=(len(fg_inds) - num_fg), replace=False)
    labels[disable_inds] = -1
```

如果负样本超过 256-num(正样本),则将多余的负样本标记为不关心样本。

#### 4.回归标签:

```
bbox_targets = np.zeros((len(inds_inside), 4), dtype=np.float32)
bbox_targets = _compute_targets(anchors, gt_boxes[argmax_overlaps, :])
```

其中: argmax\_overlaps 为 anchor 到最近的 ground truth 的标号。gt\_boxes[argmax\_overlaps,:]为 anchors 到最近的 ground truth 的坐标(左上角坐标,右下角坐标),所以 anchors 和 gt\_boxes[argmax\_overlaps,:]的维度是一样的。anchors[0,:]这个框对应的最近的 GT 为 gt\_boxes[argmax\_overlaps,:][0,:]

#### 计算 anchor 和 GT 偏差的函数

```
def bbox_transform(ex_rois, gt_rois):
    ex_widths = ex_rois[:, 2] - ex_rois[:, 0] + 1.0
    ex_heights = ex_rois[:, 3] - ex_rois[:, 1] + 1.0
    ex_ctr_x = ex_rois[:, 0] + 0.5 * ex_widths
    ex_ctr_y = ex_rois[:, 1] + 0.5 * ex_heights

gt_widths = gt_rois[:, 2] - gt_rois[:, 0] + 1.0
    gt_heights = gt_rois[:, 3] - gt_rois[:, 1] + 1.0
    gt_ctr_x = gt_rois[:, 0] + 0.5 * gt_widths
    gt_ctr_y = gt_rois[:, 1] + 0.5 * gt_heights

targets_dx = (gt_ctr_x - ex_ctr_x) / ex_widths
    targets_dy = (gt_ctr_y - ex_ctr_y) / ex_heights
    targets_dw = np.log(gt_widths / ex_widths)
    targets_dh = np.log(gt_heights / ex_heights)

targets = np.vstack(
    (targets_dx, targets_dy, targets_dw, targets_dh)).transpose()
    return targets
```

5.计算 inside\_weights, outside\_weights

这两个 weights 在计算 RPNloss 的时候会用到 a.计算 inside\_weights

只有前景(正样本)的 anchor 才会计算回归,inside\_weights 就是一个正样本的 mask。

```
bbox_inside_weights = np.zeros((len(inds_inside), 4), dtype=np.float32)
bbox_inside_weights[labels == 1, :] = np.array(cfg.TRAIN.RPN_BBOX_INSIDE_WEIGHTS)
```

```
C.TRAIN.RPN_BBOX_INSIDE_WEIGHTS = (1.0, 1.0, 1.0, 1.0)
```

b.计算 outside\_weights

outside\_weights 为正负样本的一个加权。

6.将打好标签的 label,bbox,weights 装进盒子中

a.映射到原来 anchors 的集合中(包含图片外的 anchor 的集合中)

```
# map up to original set of anchors
labels = _unmap(labels, total_anchors, inds_inside, fill=-1)
bbox_targets = _unmap(bbox_targets, total_anchors, inds_inside, fill=0)
bbox_inside_weights = _unmap(bbox_inside_weights, total_anchors, inds_inside, fill=0)
bbox_outside_weights = _unmap(bbox_outside_weights, total_anchors, inds_inside, fill=0)
```

其中 total\_anchors = int(K\*A)=h\*w\*9 inds\_inside 为在图像中的 anchors 的 索引。

```
def _unmap(data, count, inds, fill=0):
    """ Unmap a subset of item (data) back to the original set of items (of
    size count) """
    if len(data.shape) == 1:
        ret = np.empty((count, ), dtype=np.float32)
        ret.fill(fill)
        ret[inds] = data
    else:
        ret = np.empty((count, ) + data.shape[1:], dtype=np.float32)
        ret.fill(fill)
        ret[inds, :] = data
    return ret
```

# b. reshape 到网络输出的格式

生成 proposal,输入: rpn 输出的 bbox\_pred,cls\_prob,im\_info。

```
layer {
  name: 'proposal'
  type: 'Python'
  bottom: 'rpn_cls_prob_reshape'
  bottom: 'rpn_bbox_pred'
  bottom: 'im_info'
  top: 'rpn_rois'
# top: 'rpn_scores'
  python_param {
    module: 'rpn.proposal_layer'
    layer: 'ProposalLayer'
    param_str: "'feat_stride': 16"
  }
}
```

# 1.初始化一些参数:

```
cfg_key = str(self.phase) # either 'TRAIN' or 'TEST'
pre_nms_topN = cfg[cfg_key].RPN_PRE_NMS_TOP_N
post_nms_topN = cfg[cfg_key].RPN_POST_NMS_TOP_N
nms_thresh = cfg[cfg_key].RPN_NMS_THRESH
min_size = cfg[cfg_key].RPN_MIN_SIZE
```

 $pre_nms_topN = 12000$ (先选取前景框分数前 12000 的 anchor,在测试时这个数值是 6000)  $post_nms_topN = 2000$ (在 NMS 之后,再选取前景框分数前 2000 的 anchor,测试时数值为 300)  $nms_thresh = 0.7$ (NMS 时,IOU 的阈值)  $min_size = 16$ (最小的框的阈值)

2.利用 bbox\_deltas 和 anchors 产生 proposals a.产生 anchors 方法与之前的一样

b. reshape bbox\_deltas 和 scores

```
# Transpose and reshape predicted bbox transformations to get them
# into the same order as the anchors:
#
# bbox deltas will be (1, 4 * A, H, W) format
# transpose to (1, H, W, 4 * A)
# reshape to (1 * H * W * A, 4) where rows are ordered by (h, w, a)
# in slowest to fastest order
bbox_deltas = bbox_deltas.transpose((0, 2, 3, 1)).reshape((-1, 4))
```

```
# Same story for the scores:
#
# scores are (1, A, H, W) format
# transpose to (1, H, W, A)
# reshape to (1 * H * W * A, 1) where rows are ordered by (h, w, a)
scores = scores.transpose((0, 2, 3, 1)).reshape((-1, 1))
```

c. 用 bbox\_deltas 对 anchors 进行微调

```
# Convert anchors into proposals via bbox transformations
proposals = bbox_transform_inv(anchors, bbox_deltas)
```

```
def bbox_transform_inv(boxes, deltas):
    if boxes.shape[0] == 0:
        return np.zeros((0, deltas.shape[1]), dtype=deltas.dtype)

    boxes = boxes.astype(deltas.dtype, copy=False)

widths = boxes[:, 2] - boxes[:, 0] + 1.0
heights = boxes[:, 1] - boxes[:, 1] + 1.0
ctr_x = boxes[:, 0] + 0.5 * widths
ctr_y = boxes[:, 1] + 0.5 * heights

dx = deltas[:, 0::0]
dy = deltas[:, 1::0]
dw = deltas[:, 1::0]
dh = deltas[:, 2::0]
dh = deltas[:, 3::0]

pred_ctr_x = dx * widths[:, np.newaxis] + ctr_x[:, np.newaxis]
pred_ctr_y = dy * heights[:, np.newaxis] + ctr_y[:, np.newaxis]
pred_ctr_y = dy * heights[:, np.newaxis] + ctr_y[:, np.newaxis]
pred_boxe = np.exp(dw) * widths[:, np.newaxis]
pred_boxes = np.zeros(deltas.shape, dtype=deltas.dtype)
# x1
pred_boxes[:, 0::0] = pred_ctr_x - 0.5 * pred_w
# y1
pred_boxes[:, 0::0] = pred_ctr_y - 0.5 * pred_h
# x2
pred_boxes[:, 0::0] = pred_ctr_y - 0.5 * pred_h
# x2
pred_boxes[:, 0::0] = pred_ctr_y + 0.5 * pred_h
return_pred_boxes
```

3. 将 proposals 剪裁到图片之中

```
# 2. clip predicted boxes to image
proposals = clip_boxes(proposals, im_info[:2])
```

```
def clip_boxes(boxes, im_shape):
    Clip boxes to image boundaries.

# x1 >= 0
    boxes[:, 0::*] = np.maximum(np.minimum(boxes[:, 0::4], im_shape[1] - 1), 0)
# y1 >= 0
    boxes[:, 1::*] = np.maximum(np.minimum(boxes[:, 1::4], im_shape[0] - 1), 0)
# x2 < im_shape[1]
    boxes[:, 2::*] = np.maximum(np.minimum(boxes[:, 2::4], im_shape[1] - 1), 0)
# y2 < im_shape[0]
    boxes[:, 2::*] = np.maximum(np.minimum(boxes[:, 3::4], im_shape[0] - 1), 0)
    return boxes</pre>
```

4.去除 proposals 中尺寸小于阈值的

```
# 3. remove predicted boxes with either height or width < threshold
# (NOTE: convert min_size to input image scale stored in im_info[2])
keep = _filter_boxes(proposals, min_size * im_info[2])
proposals = proposals[keep, :]
scores = scores[keep]</pre>
```

```
def _filter_boxes(boxes, min_size):
    """Remove all boxes with any side smaller than min_size."""
    ws = boxes[:, 2] - boxes[:, 0] + 1
    hs = boxes[:, 3] - boxes[:, 1] + 1
    keep = np.where((ws >= min_size) & (hs >= min_size))[0]
    return keep
```

5.取 scores 前 6000 的 proposals

```
# 4. sort all (proposal, score) pairs by score from highest to lowest
# 5. take top pre_nms_topN (e.g. 6000)
order = scores.ravel().argsort()[::-1]
if pre_nms_topN > 0:
    order = order[:pre_nms_topN]
proposals = proposals[order, :]
scores = scores[order]
```

6. NMS → 取 scores 前 2000(测试时为 300)的 proposals

```
# 6. apply nms (e.g. threshold = 0.7)
# 7. take after_nms_topN (e.g. 300)
# 8. return the top proposals (-> RoIs top)
keep = nms(np.hstack((proposals, scores)), nms_thresh)
if post_nms_topN > 0:
    keep = keep[:post_nms_topN]
proposals = proposals[keep, :]
scores = scores[keep]
```

7.返回 2000 个 proposals

```
# Output rois blob
# Our RPN implementation only supports a single input image, so all
# batch inds are 0
batch_inds = np.zeros((proposals.shape[0], 1), dtype=np.float32)
blob = np.hstack((batch_inds, proposals.astype(np.float32, copy=False)))
top[0].reshape(*(blob.shape))
top[0].data[...] = blob
```

根据 GT 制作 roi 的 labels、bbox\_targets、和两个 weight,这个和之前制作 anchors 的标签类似。

Rois: [128,5] 第一列为 0,后面四列为坐标。

labels: [128,1] 分类标签

bbox\_targets: [128,4\*number\_cls],位置标签。 bbox\_inside\_weights: [128,4\*number\_cls],分类标签不为背景的 rois 的 mask bbox\_outside\_weights:与 inside\_weights 一样。

```
layer {
   name: 'roi-data'
   type: 'Python'
   bottom: 'rpn_rois'
   bottom: 'gt_boxes'
   top: 'rois'
   top: 'labels'
   top: 'bbox_targets'
   top: 'bbox_inside_weights'
   top: 'bbox_outside_weights'
   python_param {
      module: 'rpn.proposal_target_layer'
      layer: 'ProposalTargetLayer'
      param_str: "'num_classes': 7"
   }
}
```

## 1.一些初始化的设置

```
def forward(self, bottom, top):
    # Proposal ROIS (0, x1, y1, x2, y2) coming from RPN
    # (i.e., rpn.proposal_layer.ProposalLayer), or any other source
    all_rois = bottom[0].data
    # GT boxes (x1, y1, x2, y2, label)
# TODO(rbg): it's annoying that sometimes I have extra info before
# and other times after box coordinates -- normalize to one format
    gt_boxes = bottom[1].data

# Include ground-truth boxes in the set of candidate rois
    zeros = np.zeros((gt_boxes.shape[0], 1), dtype=gt_boxes.dtype)
    all_rois = np.vstack(
        (all_rois, np.hstack((zeros, gt_boxes[:, :-1])))
)

# Sanity check: single batch only
    assert np.all(all_rois[:, 0] == 0), \
        'Only single item batches are supported'

num_images = 1
    rois_per_tmage = cfg.TRAIN.BATCH_SIZE / num_images
    fg_rois_per_image = np.round(cfg_TRAIN.FG_FRACTION * rois_per_image)
```

这里把GT 框也加入到roi中了

其中: fg\_rois\_per\_image = 0.25\*128=32

2.对 rois 进行采样,并制作标签和 weight

```
# Sample rois with classification labels and bounding box regression
# targets
labels, rois, bbox_targets, bbox_inside_weights = _sample_rois(
    all_rois, gt_boxes, fg_rois_per_image,
    rois_per_image, self._num_classes)

def _sample_rois(all_rois, gt_boxes, fg_rois_per_image, rois_per_image, num_classes):
    """Generate a random sample of Rois comprising foreground and background
    examples.
    """
```

a.计算 GT 与 rois 之间的 overlaps,并将每个 roi 根据 overlap 分配到最接近的 GT 上。

```
# overlaps: (rois x gt_boxes)
overlaps = bbox_overlaps(
    np.ascontiguousarray(all_rois[:, 1:0], dtype=np.float),
    np.ascontiguousarray(gt_boxes[:, :4], dtype=np.float))
gt_assignment = overlaps.argmax(axis=1)
max_overlaps = overlaps.max(axis=1)
labels = gt_boxes[gt_assignment, 4]
```

## 其中:

gt\_assignment 的 shape 为[rois,1],值为最近的 GT 的 index。max\_overlaps 的 shape 为[rois,1],值为最大的 IOU。labels 的 shape 为[rois,1],值为最接近的 GT 的分类标签。

b.卡 IOU 阈值选取前景,并对所有前景进行采样。

```
# Select foreground RoIs as those with >= FG_THRESH overlap
fg_inds = np.where(max_overlaps >= cfg.TRAIN.FG_THRESH)[0]
# Guard against the case when an image has fewer than fg_rois_per_image
# foreground RoIs
fg_rois_per_this_image = int(min(fg_rois_per_image, fg_inds.size))
# Sample foreground regions without replacement
if fg_inds.size > 0:
    fg_inds = npr.choice(fg_inds, size=fg_rois_per_this_image, replace=False)
```

#### 其中:

TRAIN.FG\_THRESH = 0.5,表示 rois 与 GT 最大的 IOU 超过 0.5,则设置为前景。fg\_rois\_per\_this\_image 最大为 32。所以前景最多采样 32 个。

c.卡 IOU 阈值选取背景,并对所有的背景进行采样。

## 其中:

TRAIN.BG\_THRESH\_HI=0.5 TRAIN.BG\_THRESH\_LO=0.1 所以 rois 与 GT 最大的 IOU 在  $0.1\sim0.5$  范围之内的标记为背景。 背景 rois 最多为 128-32=96 个。

d. 根据 b,c 两步选出的前后背景的 inds(索引)来选出其 labels,和坐标

```
# The indices that we're selecting (both fg and bg)
keep_inds = np.append(fg_inds, bg_inds)
# Select sampled values from various arrays:
labels = labels[keep_inds]
# Clamp labels for the background RoIs to 0
labels[fg_rois_per_this_image:] = 0
rois = all_rois[keep_inds]
```

## 注意:

需要将背景的分类标签置为 0, 这里 labels 为前面采样出来的 roi 的分类标签。 rois 为前面采样出来的 roi 的位置坐标。

e. 计算出采样出的 rois 与其最近的 GT 之间的偏差(即为 bbox\_targets)

```
bbox_target_data = _compute_targets(
    rois[:, 1:5], gt_boxes[gt_assignment[keep_inds], :4], labels)
```

## 注意:

这里返回的为分类标签和位置标签,这是为了后面制作与输出对应的回归标签,因为需要分类标签。即 shape 为[128,5]第一列为分类标签,后四列为位置标签。

f.制作与输出对应的回归标签,和权重。

```
bbox_targets, bbox_inside_weights = \
    _get_bbox_regression_labels(bbox_target_data, num_classes)
```

```
Get_bbox_regression_labels(bbox_target_data, num_classes):
    """Bounding-box regression targets (bbox_target_data) are stored in a
    compact form N x (class, tx, ty, tw, th)

This function expands those targets into the 4-of-4*K representation used
by the network (i.e. only one class has non-zero targets).

Returns:
    bbox_target (ndarray): N x 4K blob of regression targets
    bbox_inside_weights (ndarray): N x 4K blob of loss weights

"""

clss = bbox_target_data[:, 0]
    bbox_targets = np.zeros((clss.size, 4 * num_classes), dtype=np.float32)
    bbox_inside_weights = np.zeros(bbox_targets.shape, dtype=np.float32)
    inds = np.where(clss > 0)[0]
    for ind in inds:
        cls = clss[ind]
        start = int(4 * cls)
        end = start + 4
        bbox_targets[ind, start:end] = bbox_target_data[ind, 1:]
        bbox_targets[ind, start:end] = cfg.TRAIN.BBOX_INSIDE_WEIGHTS
    return bbox_targets, bbox_inside_weights
```

```
layer {
    name: "bbox_pred"
    type: "InnerProduct"
    bottom: "fc7"
    top: "bbox_pred"
    param { lr_mult: 1.0 }
    param { lr_mult: 2.0 }
    inner_product_param {
        num_output: 28
        weight_filler {
            type: "gaussian"
            std: 0.001
    }
```

可以看到,全链接输出的为[N,28](这里类别数是 7) 所以,我们要将之前得到的[N,4]的位置标签, 结合[N,1]的分类标签来生成与输出匹配的[N,28]的标签.

#### 其中:

 $TRAIN.BBOX_INSIDE_WEIGHTS = (1.0, 1.0, 1.0, 1.0)$ 

可以看到,这里是将位置标签复制到对应的类处。 inside\_weights 的制作相同。

g. outside\_weight

```
# bbox_outside_weights
top[*].reshape(*bbox_inside_weights.shape)
top[*].data[...] = np.array(bbox_inside_weights > *).astype(np.float32)
```

outside\_weight 与 inside\_weight 一样。

Roipooling:

根据 roi 的位置坐标来计算其对应区域的特征。

输入: rois,位置坐标

conv5, 基础网络特征

输出: [128,6,6]

```
layer {
  name: "roi_pool_conv5"
  type: "ROIPooling"
  bottom: "conv5"
  bottom: "rois"
  top: "roi_pool_conv5"
  roi_pooling_param {
    pooled_w: 6
    pooled_h: 6
    spatial_scale: 0.0625 # 1/16
  }
}
```

roipooling 具体源码解读可以看这篇博客: <a href="http://blog.csdn.net/lanran2/article/details/60143861">http://blog.csdn.net/lanran2/article/details/60143861</a>

# 两个全连接层:

```
layer {
  name: "fc6"
  type: "InnerProduct"
  bottom: "roi_pool_conv5"
  top: "fc6"
  param { lr_mult: 1.0 }
  param { lr_mult: 2.0 }
  inner_product_param {
    num_output: 4096
  }
}
layer {
  name: "relu6"
  type: "ReLU"
  bottom: "fc6"
  top: "fc6"
}
layer {
  name: "drop6"
  type: "Dropout"
  bottom: "fc6"
  top: "fc6"
  dropout_param {
    dropout_param {
    dropout_ratio: 0.5
    scale_train: false
  }
}
```

```
layer {
  name: "fc7"
  type: "InnerProduct"
  bottom: "fc6"
  top: "fc7"
  param { lr_mult: 1.0 }
  param { lr_mult: 2.0 }
  tnner_product_param {
      num_output: 4096
  }
}
layer {
  name: "relu7"
  type: "ReLU"
  bottom: "fc7"
  top: "fc7"
}
layer {
  name: "drop7"
  type: "Dropout"
  bottom: "fc7"
  top: "fc7"
  top: "fc7"
  dropout_param {
      dropout_param {
      dropout_param {
      dropout_ratto: 0.5
      scale_train: false
  }
}
```

## 由全连接层得到位置预测:

```
layer {
  name: "bbox_pred"
  type: "InnerProduct"
  bottom: "fc7"
  top: "bbox_pred"
  param { lr_mult: 1.0 }
  param { lr_mult: 2.0 }
  inner_product_param {
     num_output: 28
     weight_filler {
       type: "gaussian"
       std: 0.001
     }
     bias_filler {
       type: "constant"
       value: 0
     }
  }
}
```

# 由全连接层得到类别预测:

```
layer {
  name: "cls_score"
  type: "InnerProduct"
  bottom: "fc7"
  top: "cls_score"
  param { lr_mult: 1.0 }
  param { lr_mult: 2.0 }
  inner_product_param {
     num_output: 7
     weight_filler {
       type: "gaussian"
       std: 0.01
   }
  bias_filler {
      type: "constant"
      value: 0
   }
}
```

由之前的 roi-data 层产生的 labels 标签生成分类 loss:

```
layer {
  name: "loss_cls"
  type: "SoftmaxWithLoss"
  bottom: "cls_score"
  bottom: "labels"
  propagate_down: 1
  propagate_down: 0
  top: "cls_loss"
  loss_weight: 1
  loss_param {
    ignore_label: -1
    normalize: true
  }
}
```

由之前的roi-data 层产生的rpn\_bbox\_targets 标签,inside\_weight,outside\_weight 生成回归的 loss

layer [
 name: "loss\_bbox"
 type: "SmoothL1Loss"
 bottom: "bbox\_pred"
 bottom: "bbox\_targets"
 bottom: 'bbox\_inside\_weights'
 bottom: 'bbox\_outside\_weights'
 top: "bbox\_loss"
 loss\_weight: 1